Projekt 1
Klasteryzacja przestrzenna danych punktowych

Celem ćwiczenia jest wyznaczenie obszarów o zwiększonej intensywności zarejestrowanych wykroczeń na terenie Krakowa. Analizę wydzielenia klastrów wykonaj używając pakietu R.

Kod R:

```
#wczytanie bibliotek
library("spatstat")
library("rgdal")
library("dbscan")
library("ggplot2")
library("broom")

#import danych
osiedla = readOGR(dsn = "pliki", layer = "osiedla", verbose = FALSE)
point = readOGR(dsn = "pliki", layer = "punkty", verbose = FALSE)

#przygotowanie brzegowych wartosci wykresu
minmax=data.frame(osiedla@bbox)
x_cor = minmax[1,]
y_cor = minmax[2,]

# przygotowanie danych punktowych do analizy
point_xy = point@coords

# DBSCAN
db = dbscan(point_xy, eps = 500, minPts = 30)

# wyswietlenie klastra miejsc wykroczen na mapie krakowa
plot(osiedla)
par(new=TRUE)
hullplot(point_xy, db,
      ylim = c(y_cor$min, y_cor$max),
      xlim = c(x_cor$min, x_cor$max),
      xlab = "x [meters]", ylab = "y[meters]",
      asp = 1, main = "DBSCAN")

#HDBSCAN
hdb = hdbscan(x = point_xy, minPts = 15)

#wyswietlenie klastra miejsc wykroczen na mapie krakowa
plot(osiedla)
par(new = TRUE)
hullplot(point_xy, hdb,
```

```
      ylim = c(y_cor$min, y_cor$max),
      xlim = c(x_cor$min, x_cor$max),
      xlab = "x [meters]", ylab = "y[meters]",
      asp = 1, main = "HDBSCAN")

#OPTICS
opt = optics(x=point_xy, eps = 1500, minPts = 30)

#Prog do identyfikacji klastrow
db_opt = extractDBSCAN(opt, eps_cl = .1)

#Prog stromosci do hierarchicznej identyfikacji klastrow przy uzyciu metody Xi.
db_opt = extractXi(opt, xi = 0.01)

# wyswietlenie klastra miejsc wykroczen na mapie krakowa
plot(osiedla)
par(new = TRUE)
hullplot(point_xy, db_opt,
      ylim = c(y_cor$min, y_cor$max),
      xlim = c(x_cor$min, x_cor$max),
      xlab = "x [meters]", ylab = "y[meters]",
      asp = 1, main = "OPTICS")
```

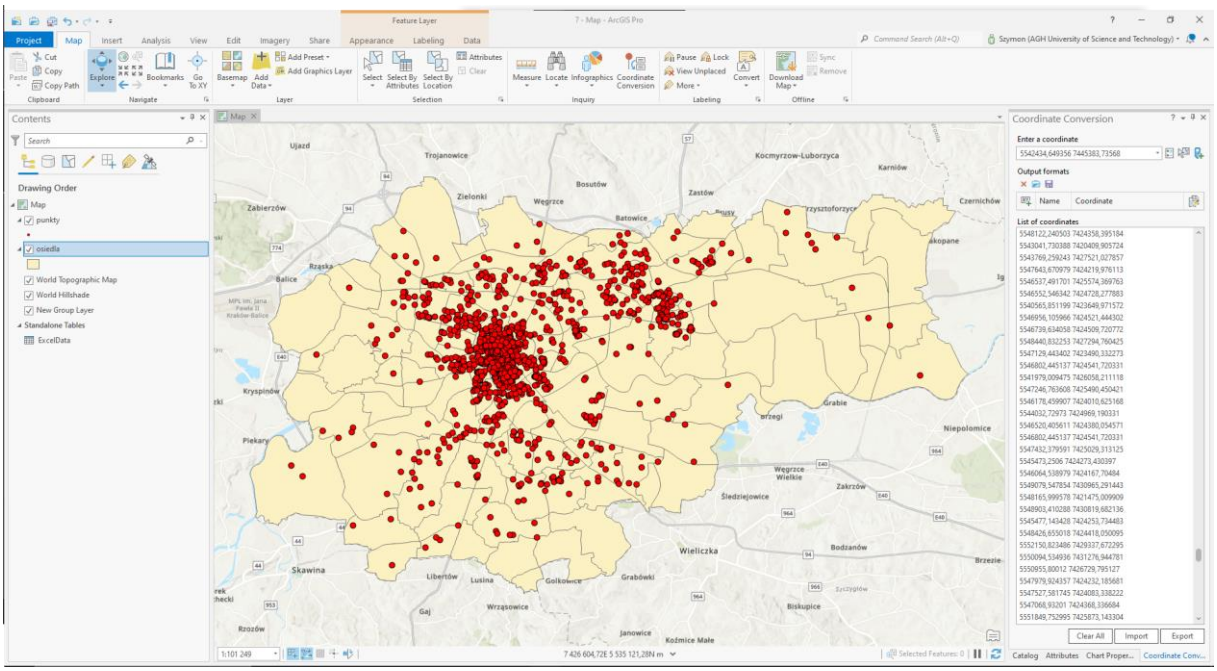

Screen 1. „*wizualizacja punktów z zmienionym układem współrzędnych*”

Opis funkcji:

DBSCAN
Ma dwa argumenty „eps”, czyli minimalna odległość łącząca 2 punkty by mógł powstać klaster, oraz „minPts”, czyli minimalna ilość obserwacji by mógł powstać klaster

Zalety:
- -Odporny na wpływ obserwacji odstających.
- -Znakomicie radzi sobie z grupami o niewypukłym kształcie.
- -Daje dobre rezultaty.
- -Daje możliwość definiowania wielu miar.

Wady:
- -Nie daje możliwości definiowania a priori liczby segmentów .
- -Dobór odpowiednich parametrów bywa dosyć problematyczny.

HDBSCAN
Ma jeden argument „minPts” działający tak jak w DBSCAN.
HDBSCAN zasadniczo oblicza hierarchię wszystkich klastrów DBSCAN, a następnie wykorzystuje metodę ekstrakcji opartą na stabilności, aby znaleźć optymalne cięcia w hierarchii, tworząc w ten sposób płaskie rozwiązanie.

Zalety:
- -Posiada wszystkie zalety DBSCAN
- -Dodatkowo ma mniejszą wrażliwość niż DBSCAN
- -Ma dobrą stabilność w przypadku doboru parametrów

Wady:
- -Największą wadą jest dobór odpowiednich wartości domyślnych

OPTICS
Podobnie jak DBSCAN ma 2 argumenty „eps” oraz „minPts”

Zalety:
- -Nie ma problemu z rozpoznawaniem klastrów o bardzo małej gęstości
- -Zmniejszona wrażliwość na parametry wejściowe

Wady:
- -Trudniejszy do zrozumienia w porównaniu z metodą DBSCAN

Wyniki klasteryzacji wraz z podaniem użytych parametrów:

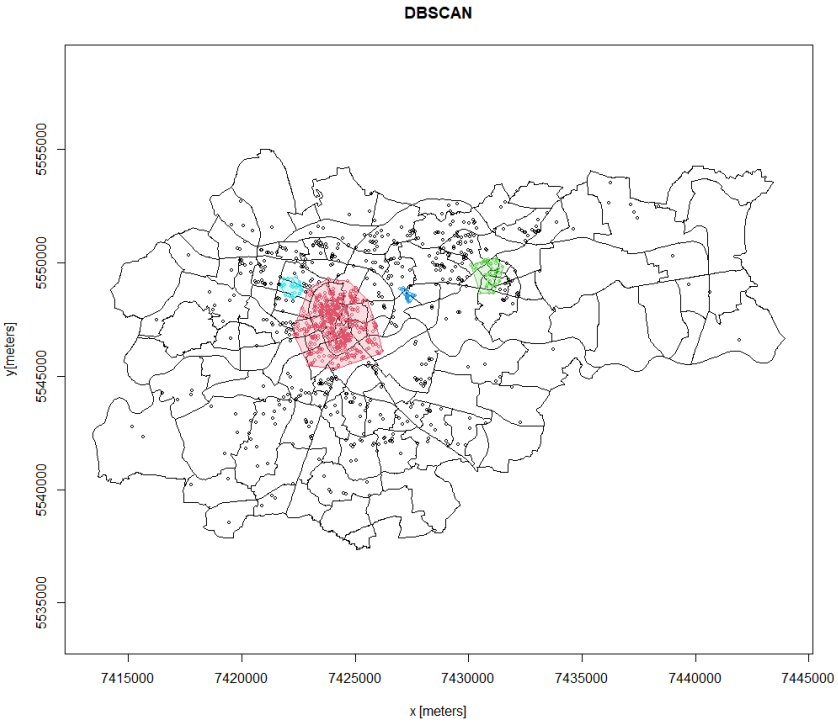

dbscan(point_xy, eps = 500, minPts = 30)

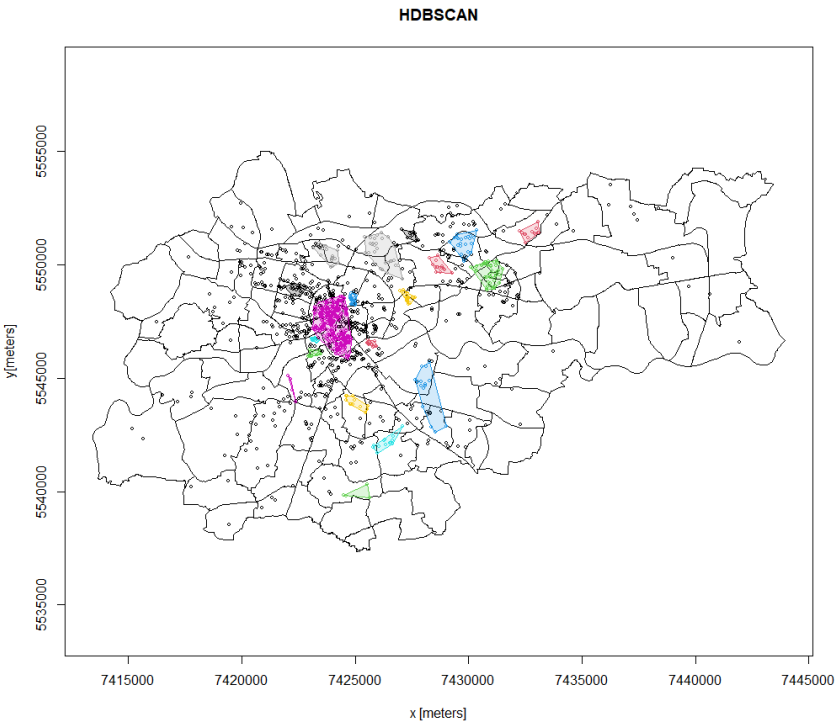

hdbscan(x = point_xy, minPts = 15)

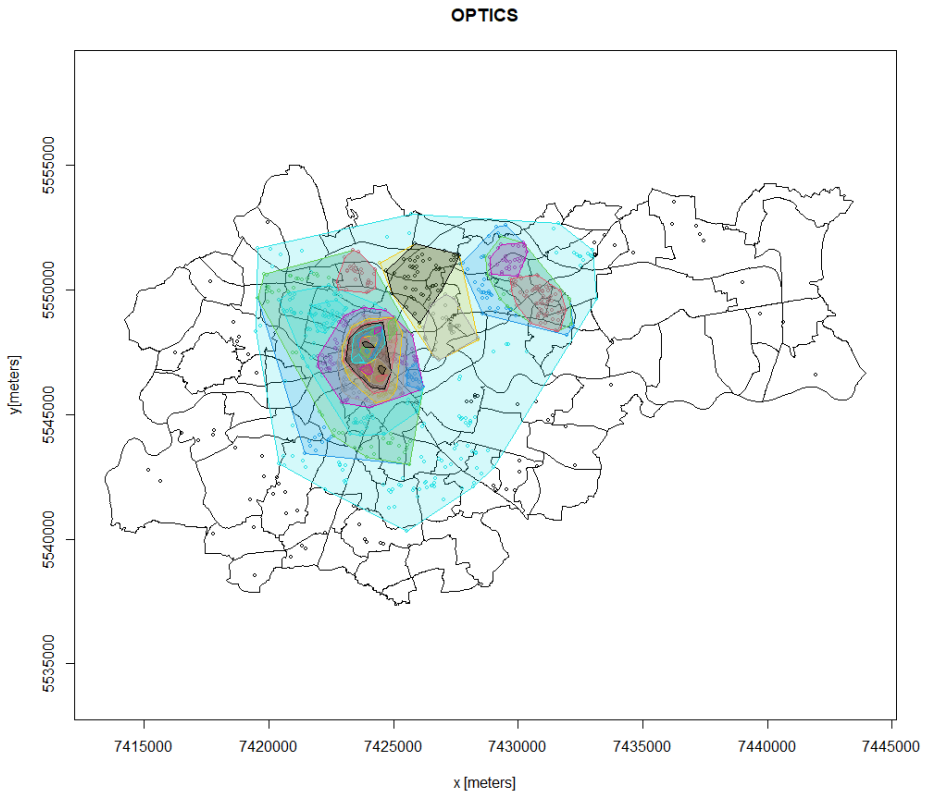

opt = optics(x=point_xy, eps = 1500, minPts = 30)
db_opt = extractDBSCAN(opt, eps_cl = .1)
db_opt = extractXi(opt, xi = 0.01)

Porównanie wyników i wnioski :
Na przedstawionych wykresach możemy zauważyć klasteryzację w zależności od warunków początkowych. Lecz na wszystkich możemy zauważyć że największa intensywność wykroczeń jest w okolicach rynku głównego, oraz w okolicach Bieńczyc Nowych oraz osiedla Teatralne. Dziwić zaś może bardzo niska ilość wykroczeń w okolicach dzielnicy Nowa Huta która w przeszłości miała miano bardzo niebezpiecznej, a obecnie według naszych danych jest jedną z najbezpieczniejszych.

Na wykresach klastrów możemy zauważyć że metoda DBSCAN różni się od metody HDBSCAN, DBSCAN tworzy klastry w oparciu o ilość punktów oraz maksymalny promień od punktu podany w definicji metody, tworząc grupy o różnej gęstości występowania, zaś metoda HDBSCAN tworzy wszystkie możliwe klastry a następnie zostawia tylko te które mają podobną gęstość występowania punktów na swoim obszarze (metoda ta tworzy różne klastry o różnej gęstości punktów, jedynym warunkiem jest ilość punktów jaka musi występować w nie większej odległości niż eps wyznaczony w danym momencie przez program)
Klaster OPTIC tworzy zaś wiele obszarów które mogą się nachodzić na siebie, zlicza on odpowiednie punkty podobnie jak w DBSCAN, uzupełniając to progiem do identyfikacji klastrów oraz progiem stromości do hierarchicznej identyfikacji klastrów przy użyciu metody XI.

Bibliografia:

https://mateuszgrzyb.pl/grupowanie-gestosciowe-dbscan-teoria/
https://en.wikipedia.org/wiki/OPTICS_algorithm
https://hdbscan.readthedocs.io/en/latest/comparing_clustering_algorithms.html